

Rot Corn Grain Classification by Color and Texture Analysis

Gustavo Vias de Brito Silva and Franklin César Flores

Abstract— Due to the constant increase in corn production and exportation volume, it is becoming increasingly necessary to control the activities and to automate the processes related to shipment and reception of this product. This paper proposes a new methodology that aims to handle the governance and compliance in the process of burnt corn grain classification, which directly impacts in the quality and marketing price of this cereal. This methodology is based on the implementation of image processing techniques combined with feature extraction and minimal distance classifier to estimate the burnt grain percentage in the corn sample. It was built an image database, by containing corn samples with different burnt grain percentages. The Manhattan, Bray-Curtis and Kullback-Leibler distance functions were adopted to create a criteria of similarity between these digital images. The obtained results were attributed to supervised classifying algorithms as test and training sets, making possible to analyze the accuracy and complexity of the proposed method.

Index Terms—Corn grain classification. Color analysis. Texture analysis. Image analysis

I. INTRODUÇÃO

A produção de milho é um dos principais e mais rentáveis ramos da agricultura mundial e consolida o Brasil como terceiro maior produtor e segundo maior exportador dessa cultura. Somente na safra 2020/21, é estimada uma produção recorde de 109 milhões de toneladas. Esse valor representa 6,76 milhões de toneladas a mais do que na safra 2019/20 [1].

Com o constante aumento no volume de milho produzido no Brasil e no mundo, é cada vez maior a necessidade de transformação digital e automatização das operações. Consequentemente, o uso da tecnologia é de fundamental importância para garantir o bom desempenho e segurança dos processos realizados dentro desse contexto. Embora alguns dos procedimentos realizados pelas empresas do ramo agrícola em relação às atividades de classificação (análise da qualidade) de cereais sejam realizados de forma automatizada (classificação de umidade, por exemplo), outras ainda são executadas manualmente, como por exemplo a detecção da porcentagem de grãos ardidos em meio à grãos de milho sadios [2].

São considerados grãos ardidos de milho os grãos dessa cultura que possuem pelo menos um quarto da sua superfície com descoloração, podendo variar do marrom claro ao roxo ou do vermelho claro ao vermelho intenso. Essa descoloração está frequentemente relacionada à fermentação/podridão das espigas acometidas por fungos, mas também pode ocorrer por grãos queimados (elementos carbonizados no processo de secagem) [2]. Dentre os fungos mais comuns, podemos citar

G. V. B. Silva, Departamento de Informática, Universidade Estadual de Maringá, Maringá, Paraná, Brasil.

F. C. Flores, Departamento de Informática, Universidade Estadual de Maringá, Maringá, Paraná, Brasil.

os do tipo *Fusarium verticillioides* e *Diplodia (Stenocarpella spp.)* [3]. Estas alterações afetam diretamente na qualidade e, consequentemente, no processo de comercialização desses grãos. Logo, a correta classificação é fundamental para aumentar a rentabilidade e qualidade do milho que será armazenado e comercializado posteriormente [4].

A classificação de grãos é o ato de determinar a qualidade do produto (milho), sejam elas intrínsecas ou extrínsecas, de modo a identificar diferentes tipos de características e uniformidades em relação ao padrão estabelecido. Os padrões e parâmetros oficiais para a classificação de grãos, bem como os critérios definidos nesse processo são aprovados pelo governo federal (Ministério da Agricultura, Pecuária e Abastecimento - MAPA). No entanto, além dessa classificação oficial estabelecida pelos padrões governamentais, existe também a classificação comercial que é fundamentada por meio de contrato entre comprador e vendedor. Nestas situações, a empresa compradora tem autonomia para determinar o padrão de classificação dos grãos que ela está recebendo do produtor, estabelecendo valores de recebimento, desconto ou recusa da carga, a depender da porcentagem de grãos ardidos, impurezas e umidade presentes na amostra analisada [2].

O processo de classificação comercial, comumente utilizado pelas empresas do ramo agrícola, é realizado sempre no recebimento (operação de entrada dos produtos oriundos da lavoura do produtor rural) e na expedição (produtos que estão armazenados na empresa), em que o estado desses grãos é avaliado a partir da análise de uma amostra representativa da carga. Desse modo, o procedimento de triagem inicia-se com a obtenção dos grãos. Para tanto, com o auxílio de um calador mecânico ou manual, são coletadas pequenas amostras de diferentes pontos e profundidades da carga. Em seguida, os grãos coletados são homogeneizados, no intuito de obter uma amostra uniforme para o processo de classificação [5]. Por meio da amostra coletada, é possível então realizar o processo de classificação e, entre os diversos tipos de análise, estimar o percentual de grãos ardidos de milho. Para essa etapa, o classificador (usuário especialista responsável por inspecionar a qualidade do grão) reserva uma pequena parte da amostra (normalmente 250 ou 500 gramas), a qual será objeto de estudo para análise (Fig. 2a). Na sequência, o classificador separa manualmente os grãos ardidos de milho dos grãos normais (Fig. 2b). Os grãos ardidos identificados são pesados separadamente (Fig. 2c). Logo, por meio da proporção entre o peso da amostra de grãos ardidos e peso total da amostra analisada, é possível calcular o percentual de grãos ardidos presente na carga [2].

No intuito de automatizar e aumentar a confiabilidade do processo de classificação comercial de grãos de milho e

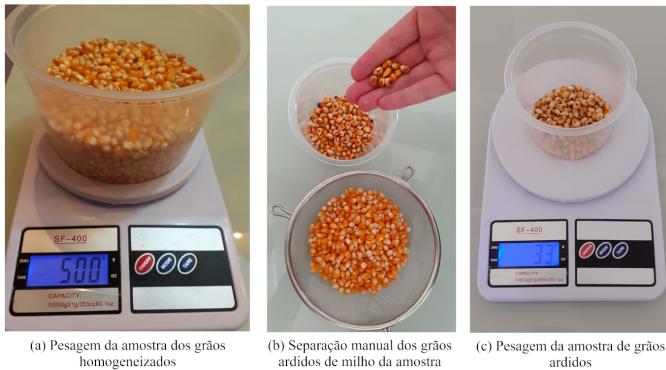


Fig. 1. Processo classificação comercial de grãos ardidos de milho.

reduzir a subjetividade da análise individual, o objetivo deste trabalho é apresentar uma metodologia que possibilite estimar a faixa percentual de grãos ardidos de milho por meio da análise global (estudo de todos os *pixels*) das características intrínsecas às imagens. Essa faixa pode ser definida de acordo com os critérios adotados por cada empresa compradora de grãos, visto que elas possuem autonomia para padronizar os percentuais de grãos ardidos dentro de um intervalo de valores limitado e previamente estabelecido (classificação comercial).

II. CONCEITOS PRELIMINARES

A aprendizagem de máquina, ou machine learning (ML), consiste no processo de implementação de um sistema computacional que seja, por si só, capaz de realizar determinadas atividades sem estar explicitamente programado para isto, fundamentando-se apenas em um treinamento prévio por meio de um conjunto de dados. O método de classificação supervisionada é uma das implementações para o processo de ML e utilizam informações rotuladas para criação do modelo de treinamento. Consequentemente, para classificar dados oriundos de imagens digitais é necessário que as características intrínsecas a estas sejam previamente extraídas [6].

A. Extração de Características

Essas características podem ser obtidas por meio de descriptores de imagens, como por exemplo, cor e textura. Logo, a imagem poderá ser representada por um conjunto de dados, também denominado vetor de características, no qual cada elemento representa um atributo extraído da imagem [7].

1) *Descriptor de Cor:* O processo de extração de características em imagens digitais por meio de descriptores de cor é bastante robusto, uma vez que esses atributos pouco dependem do tamanho, orientação e ângulo de visão da imagem. Para que seja possível quantificar as características de cor de uma imagem, é necessário definir um espaço de cor [8]. O espaço RGB, que consiste em três diferentes canais de cores (R=vermelho, G=verde e B=azul), é um dos modelos mais utilizados em problemas relacionados a processamento de imagens e visão computacional [9]. Cada elemento (*pixel*) presente no espaço RGB possui 256 tons, nos quais os respectivos valores podem variar entre 0 e 255. Portanto, cada elemento pode ser representado digitalmente

por 8 bits [10]. As principais vantagens do espaço de cores RGB estão relacionadas à baixa complexidade computacional e a robustez em relação a alterações geométricas. Além disso, é um modelo que pode ser representado de forma compacta [11]. O histograma de cor é uma das formas mais diretas e efetivas para representar as características de cor [11]. O histograma é idealizado por meio da contagem da distribuição de frequências de tons presentes em cada *pixel* da imagem, de acordo com o espaço de cores utilizado. Um histograma de cores, no espaço RGB com profundidade de 24-bits, pode ser representado por um vetor com 768 atributos (256 atributos para cada banda RGB). Por conseguinte, o processo de construção do histograma visa incrementar cada uma dessas posições de acordo com o respectivo valor de tonalidade encontrado em cada *pixel*. Portanto, o eixo vertical y do histograma é formado pela quantidade de ocorrências de cada atributo (eixo x), representando a distribuição (ou densidade) de frequência desses elementos [10].

2) *Descriptor de Textura:* A representação do conteúdo por meio de textura é uma das abordagens para descrever regiões de uma imagem. Intuitivamente, esses elementos de textura descrevem propriedades com suavidade, rugosidade e regularidade da imagem [12]. Um dos operadores para extração e representação de textura é o *Local Binary Pattern* (LBP). O método LBP tem como objetivo computar cada pixel da imagem por meio de um padrão binário local de acordo com os elementos da vizinhança desse pixel. Mediante a contagem de ocorrências desse padrão, torna-se possível a construção do histograma de textura. Logo, o histograma construído por meio da aplicação do LBP pode ser utilizado como um descriptor para esse tipo de característica [13]. Para tanto, caso a imagem de entrada seja colorida, o LBP realiza a conversão dessa imagem para a escala de tons de cinza (*grayscale*) [13]. Na etapa seguinte o método compara, para cada pixel q_c presente na imagem, a diferença de intensidades (nível de cinza) entre q_c e seus respectivos elementos vizinhos. Nesse caso, a vizinhança é determinada de acordo com uma região circular de raio R, na qual a centroide é definida por q_c [14]. A equação 1 representa o cálculo do código LBP para o pixel q_c .

$$LBP_{P,R(q_c)} = \sum_{p=0}^{P-1} s(x) 2^p, \quad (1)$$

onde $x = (q_p - q_c)$ é a diferença de intensidade entre os elementos vizinhos q_p e o pixel central q_c . A constante P representa o número de pixels vizinhos analisados. O cálculo da função $s(x)$ é definido pela equação 2.

$$s(x) = \begin{cases} 1, & \text{se } x = 0 \\ 0, & \text{caso contrário} \end{cases} \quad (2)$$

A Fig. 2 demonstra um exemplo de cálculo do código LBP para um determinado pixel q_c , de acordo com a equação 1.

Portanto, por meio da matriz de saída gerada por $LBP_{P,R(q_c)}$, é possível construir o histograma de textura fundamentado na extração de características [13].

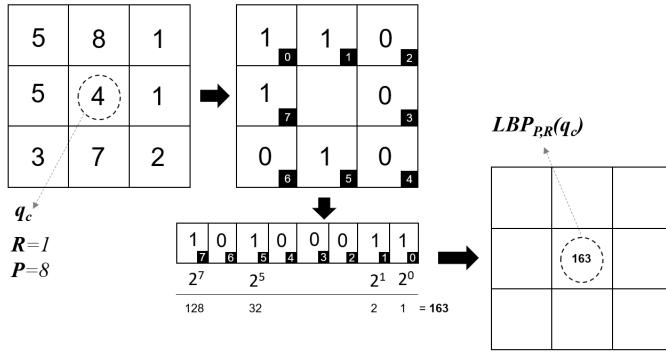


Fig. 2. Aplicação do LBP em um pixel da imagem.

B. Classificação de Objetos

A classificação de objetos é uma das importantes áreas do aprendizado de máquina e fundamentam-se em algoritmos supervisionados para estimar instâncias futuras. De acordo com um conjunto de treinamento (x_i, y_i) , no qual $x_i \in X^M$ representa cada instância formada com M características e y_i representa a classe real k de x_i , o processo de classificação supervisionada tem como intuito estabelecer um modelo de distribuição de classes de acordo com suas respectivas características. Logo, ao surgirem novas instâncias de teste (nas quais são conhecidas as características x_i porém as classes y_i são desconhecidas), o algoritmo será utilizado para estimar a classe k por meio da distribuição construída com base no conjunto de treinamento [15].

1) *Classificador de Distância ao Protótipo:* O classificador de distância ao protótipo utiliza métodos fundamentados em casamento (*matching*), nos quais cada classe de objetos é representada por um vetor de características protótipo, baseado nos elementos do conjunto de treinamento. Assim sendo, por meio de uma métrica estabelecida, novos padrões de características (desconhecidos a priori) são atribuídos à classe mais próxima. Uma das abordagens é a classificação por distância mínima, a qual utiliza funções de distância para estabelecer um critério de proximidade entre os vetores protótipos e os novos elementos com padrão desconhecido. O classificador considera, portanto, o menor valor de distância obtido para atribuir o novo elemento a uma determinada classe [12].

Ao estabelecer o protótipo para cada classe de objetos como sendo o vetor médio entre os elementos, o cálculo do centroide (e, portanto, o vetor protótipo) de cada classe será definido pela equação 3 [16].

$$v_r = \frac{1}{N_r} \sum_{n=1}^{N_r} x_n, \quad r = 1, 2, \dots, R \quad (3)$$

onde r é o rótulo de cada classe, N_r é a quantidade de vetores de características da classe r , x_n representa cada um desses vetores e R é o número de classes padrões do conjunto de treinamento.

Por meio de uma função de distância é possível calcular o quão próximo um vetor de características x desconhecido está de cada um dos protótipos v_r . Consequentemente, x será atribuído à classe de rótulo r caso o valor de distância

seja o menor entre todas as classes [12]. Assim sendo, é importante escolher o método mais adequado de acordo com o conjunto de dados. Diversas funções foram propostas na literatura para realizar o cálculo da distância entre dois objetos [17], entre elas as distâncias de *Manhattan*, *Bray-Curtis* (BC) e *Kullback–Leibler* (KL).

Também conhecida como L_1 [18], a distância de Manhattan foi proposta por Hermann Minkowski no final do século 19 [19], e pode ser representada por meio da equação 4. Logo, é possível definir a distância de Manhattan como a somatória da diferença absoluta entre cada i -ésimo elemento de dois conjuntos x e y [20].

$$L_1((x_1, \dots, x_n), (y_1, \dots, y_n)) = \sum_{i=1}^n |x_i - y_i| \quad (4)$$

A função de distância *Bray-Curtis* (BC), representada pela equação 5, é também conhecida como método de normalização e é comumente utilizada nas áreas de botânica, ecologia e ciência ambiental [21]. Como resultado, a função BC retorna um valor de distância entre 0 e 1. Então, quanto mais próximo o valor é de zero, maior será similaridade entre os elementos analisados. Analogamente, menor será o nível de similaridade entre ambos os elementos caso a distância obtida esteja próxima do valor um [22].

$$BC((x_1, \dots, x_n), (y_1, \dots, y_n)) = \frac{\sum_{i=1}^n |x_i - y_i|}{\sum_{i=1}^n (x_i + y_i)} \quad (5)$$

Utilizado para calcular a distância entre duas funções densidade de probabilidade (PDFs) [23], o método de divergência *Kullback–Leibler* (KL) tem sido frequentemente empregado em problemas relacionados a reconhecimento de padrões, processamento de imagens, classificação e detecção de anomalias. Também conhecida como entropia relativa, a divergência KL é uma medida assimétrica para cálculo da distância entre duas PDFs $p(x)$ e $q(x)$, conforme equação 6 [24]. Assim sendo, quanto menor valor da distância KL, mais semelhantes serão $p(x)$ e $q(x)$.

$$KL(p||q) = \sum_{i=1}^n p(x_i) \cdot \log \frac{p(x_i)}{q(x_i)} \quad (6)$$

III. MÉTODO PROPOSTO

A. Aquisição da Imagem

A captura e obtenção das imagens de grãos de milho arrido foi realizada por meio da estrutura apresentada na Fig. 3. O item A é composto por dois suportes, ambos compostos por uma lâmpada de LED 6500K de 9W. O item B representa a estrutura projetada para apoiar a dispositivo de captura das imagens (item C), na qual foi utilizada a câmera digital do aparelho Samsung M20, com 13.0 MP (3096 x 4128, 72 dpi). As amostras de grãos de milho arrido, representadas pelo item D, foram colocadas dentro de uma caixa e posicionadas em uma mesa (item E) a uma distância de 17cm da câmera digital.

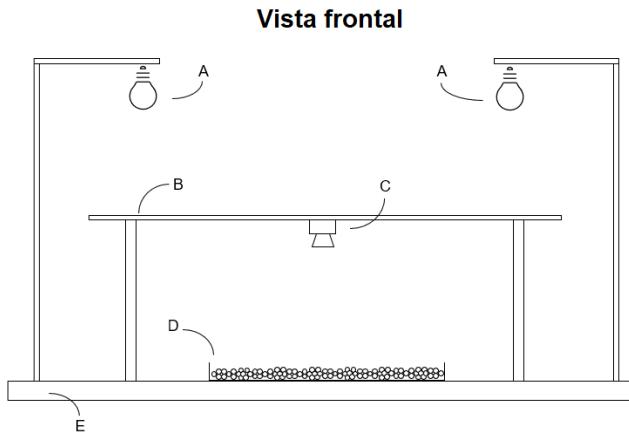


Fig. 3. Estrutura construída para captura das imagens.

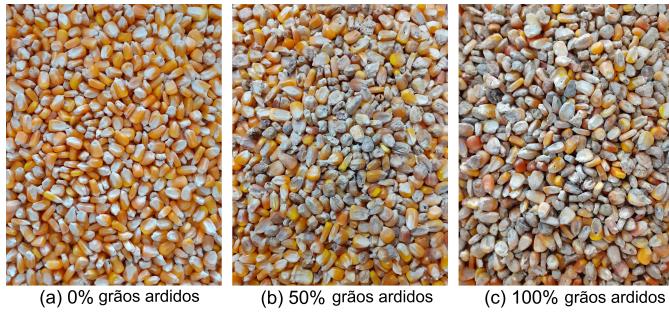


Fig. 4. Exemplo das imagens de acordo com o percentual de grãos ardidos.

Deste modo, foi construída uma base de imagens, na qual os objetos capturados foram divididos em classes de acordo com o percentual de grão ardido de cada amostra, conforme demonstrado na Tabela I. Para cada classe, foram capturadas 100 imagens de amostras de grãos de milho, totalizando 3.300 imagens. A Fig. 4 demonstra exemplos de três classes diferentes das imagens capturadas.

TABELA I
CLASSES E RESPECTIVOS PERCENTUAIS DE GRÃOS ARDIDOS

Classes e respectivos percentual de grãos ardidos		
Classe 0 - 0% grãos ardidos	Classe 11 - 11% grãos ardidos	Classe 22 - 50% grãos ardidos
Classe 1 - 1% grãos ardidos	Classe 12 - 12% grãos ardidos	Classe 23 - 55% grãos ardidos
Classe 2 - 2% grãos ardidos	Classe 13 - 13% grãos ardidos	Classe 24 - 60% grãos ardidos
Classe 3 - 3% grãos ardidos	Classe 14 - 14% grãos ardidos	Classe 25 - 65% grãos ardidos
Classe 4 - 4% grãos ardidos	Classe 15 - 15% grãos ardidos	Classe 26 - 70% grãos ardidos
Classe 5 - 5% grãos ardidos	Classe 16 - 20% grãos ardidos	Classe 27 - 75% grãos ardidos
Classe 6 - 6% grãos ardidos	Classe 17 - 25% grãos ardidos	Classe 28 - 80% grãos ardidos
Classe 7 - 7% grãos ardidos	Classe 18 - 30% grãos ardidos	Classe 29 - 85% grãos ardidos
Classe 8 - 8% grãos ardidos	Classe 19 - 35% grãos ardidos	Classe 30 - 90% grãos ardidos
Classe 9 - 9% grãos ardidos	Classe 20 - 40% grãos ardidos	Classe 31 - 95% grãos ardidos
Classe 10 - 10% grãos ardidos	Classe 21 - 45% grãos ardidos	Classe 32 - 100% grãos ardidos

B. Extração de Características

Os atributos das imagens são representados por meio de histogramas de cor e textura, mediante a extração de características de cada item da base de dados.

Para as características de cor, utilizou-se o espaço *RGB*, no qual cada imagem colorida de 24-bits foi dividida em três bandas, no intervalo [0,255]. Para cada banda, foi calculado um histograma.

As características de textura foram obtidas por meio da aplicação do algoritmo *LBP*, utilizando o método *default* e os parâmetros de raio igual a 1 e número de pontos igual a 8 nas imagens em escala de cinza. Com o resultado obtido por meio do método *LBP* foi possível criar o histograma de textura para cada imagem da base de dados.

C. Classificação

Por meio da extração de características das imagens e definição de seus respectivos histogramas (cor e textura), foi possível aplicar o processo de classificação, no intuito de estimar a classe e acurácia do método.

O algoritmo proposto para cálculo da classe estimada inicia-se com a definição e obtenção de um histograma médio para cada percentual de grãos ardidos, conforme Tabela 3. O cálculo foi realizado por meio da média simples entre 20 histogramas de imagens de cada classe, os quais foram definidos como *conjuntos de treinamento*.

Em sequência, realizou-se a segmentação das imagens da base de acordo com suas respectivas classes reais, as quais foram divididas em cinco *conjuntos de teste* (por classe).

Seguindo o fluxo da metodologia proposta, a etapa posterior foi baseada em estabelecer um critério de similaridade entre os histogramas de imagens dos *conjuntos de teste* e os objetos contidos nos *conjuntos de treinamento*, a fim de estimar a classe (percentual de grão ardido) de cada imagem analisada. Deste modo, por meio das funções *LI*, *BC* e *KL*, foram calculadas as distâncias entre cada elemento do *conjunto de teste* e os histogramas médios das classes (*conjuntos de treinamento*). Consequentemente, a classe **estimada** de cada imagem do *conjunto de teste* é definida de acordo com a classe **real** do histograma médio mais próximo a esta imagem, uma vez que o menor valor de distância obtido representa maior semelhança entre os elementos.

Após estimar o percentual de grão ardido de todas as imagens da base, foi possível comparar se a classe **prevista** é igual à classe **real** de cada imagem. Deste modo, foi possível calcular a taxa de acertos/erros do método proposto e estabelecer a acurácia de cada *conjunto de teste*. Portanto, a acurácia de cada classe foi definida por meio da média entre os percentuais obtidos para cada conjunto.

IV. RESULTADOS EXPERIMENTAIS E DISCUSSÕES

Os resultados foram obtidos aplicando-se o método proposto na base de imagens de grãos ardidos. O principal objetivo do presente trabalho foi estimar a classe de cada objeto analisado e, consequentemente, prever o percentual de grãos ardidos em cada amostra.

A fim de estabelecer um critério para verificar a acurácia do método, considerou-se as classes da Tabela I em intervalos de percentuais de grãos ardidos, conforme Tabela II. A ideia principal dos experimentos realizados é encontrar a superclasse de uma imagem do conjunto de testes apenas por meio de suas características intrínsecas. Deste modo, foi considerado como acerto quando o método classifica (por meio da comparação entre os histogramas) que a classe estimada de uma imagem de teste está contida na superclasse real da imagem (classificação

supervisionada). Por exemplo, se uma imagem pertence à classe 2 (classe real) e o método classificou essa imagem na classe 5 (classe estimada), apontamos como correta, uma vez que as classes 2 e 5 pertencem à mesma superclasse. Para verificar a divergência entre as classes real e estimada, foi calculado o desvio da classe, que representa quantas classes existem entre elas. Por exemplo, se a classe real é 2 e a classe estimada é 5, o desvio da classe será 3.

TABELA II
DEFINIÇÃO DAS FAIXAS DE CLASSES E RESPECTIVAS *superclasses*

Classes	Superclasse	Definição
0 a 8	0	Faixa aceitável, na qual o grão é recebido sem desconto
9 a 15	1	Faixa aceitável, porém haverá um desconto aplicado sobre a carga
16 a 32	2	Fora da faixa aceitável, carga não será recebida

Os resultados apresentados são baseados no percentual médio de acurácia e desvio, o qual é definido por meio da média do número de classes existentes entre a classe estimada pelo método e a classe real da imagem. As Tabelas III e IV demonstram os resultados obtidos para os histogramas de cor, enquanto as Tabelas V e VI consideram os resultados obtidos pela comparação entre os histogramas de textura.

Conforme Tabela III, o maior valor desvio médio, representado pela distância entre as classes, foi de 1,14 (utilizando L1). Desta modo, é possível observar que, em média, o algoritmo errou a classe real da imagem apenas por um ponto percentual. Como consequência, a superclasse da imagem foi, na maioria dos casos, estimada corretamente, visto que esta representa uma faixa de classes (facilitando a detecção).

TABELA III
RESULTADOS OBTIDOS - HISTOGRAMAS DE CORES (POR CLASSE)

Classe	Distância L1		Distância BC		Distância KL	
	Acurácia	Desvio	Acurácia	Desvio	Acurácia	Desvio
0	100,00	0,18	100,00	0,16	100,00	0,18
1	100,00	0,29	100,00	0,32	100,00	0,29
2	100,00	0,50	100,00	0,35	100,00	0,54
3	100,00	0,73	100,00	0,53	100,00	0,76
4	90,00	2,49	100,00	0,75	90,00	2,38
5	87,00	3,17	95,25	1,74	87,00	3,02
6	88,25	2,10	88,75	1,64	86,75	2,35
7	93,25	2,02	95,50	1,52	93,75	1,83
8	98,25	0,76	98,75	0,88	98,00	0,71
9	97,75	1,85	97,50	1,76	97,75	1,84
10	98,00	0,70	97,75	0,78	97,75	0,70
11	93,00	1,58	92,50	1,73	93,00	1,56
12	83,00	2,77	84,75	2,47	83,00	2,75
13	95,00	1,26	96,25	1,26	93,00	1,33
14	97,50	0,98	97,75	0,80	97,75	1,02
15	99,00	1,69	96,50	1,63	98,50	1,66
16	96,00	1,20	90,50	0,91	97,75	1,17
17	94,75	0,80	96,75	0,71	99,50	0,59
18	96,75	0,51	96,25	0,52	97,00	0,52
19	99,75	0,52	98,00	0,71	99,75	0,52
20	96,25	1,96	96,50	1,98	95,25	2,11
21	100,00	1,02	100,00	0,92	100,00	0,95
22	100,00	1,34	100,00	1,30	100,00	1,35
23	100,00	0,74	100,00	0,71	100,00	0,75
24	100,00	1,67	100,00	1,49	100,00	1,57
25	100,00	1,03	100,00	0,91	100,00	0,94
26	100,00	0,52	100,00	0,48	100,00	0,49
27	100,00	1,01	100,00	1,14	100,00	0,97
28	100,00	0,32	100,00	0,57	100,00	0,46
29	100,00	0,64	100,00	0,63	100,00	0,64
30	100,00	0,62	100,00	0,55	100,00	0,64
31	100,00	0,51	100,00	0,72	100,00	0,56
32	100,00	0,25	100,00	0,13	100,00	0,20
Média	97,08	1,14	97,55	0,99	97,14	1,13

De acordo com a Tabela IV, os resultados obtidos por meio da extração de características de cor convergiram para valores expressivos de acurácia. O alto nível de acertos pode ser explicado pelo fato desses histogramas estarem bem distribuídos entre eles, facilitando a distinção da classe real da imagem. Considerando os valores obtidos por cada função de distância, pode-se notar que a melhor média de resultados de acurácia e desvio está diretamente ligada à respectiva classe da imagem. Por exemplo, o maior valor médio de acurácia para a *superclasse 0* foi obtido aplicando o método com a distância *BC* (97,58%), enquanto para a *superclasse 1* e *superclasse 2* as melhores porcentagens foram dadas pelas distâncias *L1* (94,75%) e *KL* (99,37%), respectivamente. Deste modo, pode-se observar que a função de distância mais adequada para o método dependerá da classe à qual a imagem pertence.

TABELA IV
RESULTADOS OBTIDOS - HISTOGRAMAS DE CORES (POR SUPERCLASSE)

Superclasse	Distância L1		Distância BC		Distância KL	
	Acurácia	Desvio	Acurácia	Desvio	Acurácia	Desvio
0	95,19	1,36	97,58	0,88	95,06	1,34
1	94,75	1,55	94,71	1,49	94,39	1,55
2	99,03	0,86	98,71	0,85	99,37	0,85
Média	96,32	1,26	97,00	1,07	96,27	1,25

A Fig. 5 demonstra o histograma de cor de uma imagem (curva azul) e o histograma médio da classe real (curva verde) dessa imagem. Neste caso, a classe (e, consequentemente, a superclasse) da imagem foi estimada corretamente. Pode-se notar que ambos os histogramas (azul e verde) são muito semelhantes (curva vermelha representa a diferença entre eles).

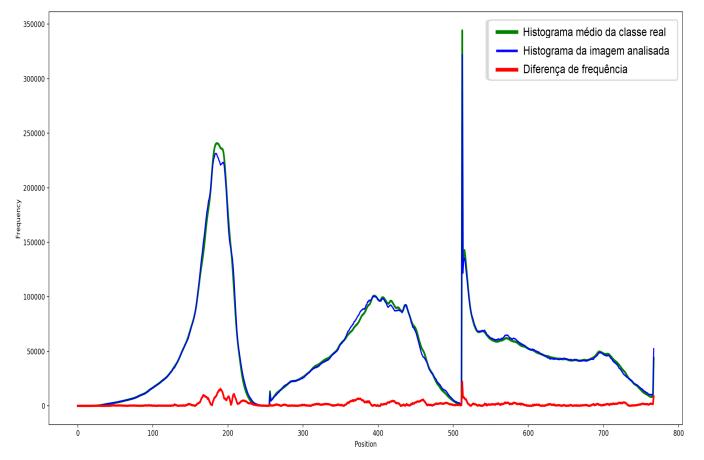


Fig. 5. Histograma de cor - classe estimada corretamente.

Por meio da Fig. 6, pode-se notar que, quando o método estima incorretamente a classe da imagem, a diferença entre alguns pontos entre o histograma médio da classe real e histograma da imagem é bastante evidente.

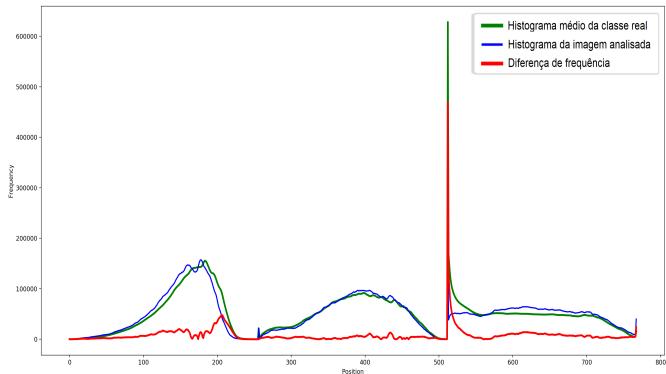


Fig. 6. Histograma de cor - classe estimada incorretamente.

A Tabela V apresenta os resultados obtidos aplicando o método proposto nos histogramas de textura. Nesse caso, a melhor média de acurácia, representada pela função de distância *L1*, convergiu para 80,61%, enquanto seu o Desvio alcançou uma diferença média de 3,22.

TABELA V
RESULTADOS OBTIDOS - HISTOGRAMAS DE TEXTURA (POR CLASSE)

Classe	Distância L1		Distância BC		Distância KL	
	Acurácia	Desvio	Acurácia	Desvio	Acurácia	Desvio
0	100,00	0,00	100,00	0,05	100,00	0,00
1	100,00	1,69	100,00	1,88	100,00	1,68
2	100,00	0,80	100,00	0,95	100,00	0,80
3	100,00	0,61	100,00	0,71	100,00	0,61
4	100,00	0,92	100,00	1,42	100,00	0,94
5	100,00	2,00	100,00	2,29	100,00	2,00
6	96,75	1,37	84,25	2,93	96,75	1,37
7	87,25	1,61	77,50	2,51	87,25	1,60
8	87,50	1,46	73,25	2,49	87,25	1,50
9	54,25	6,66	52,00	5,42	55,25	6,48
10	59,00	6,54	61,00	4,99	58,75	6,57
11	60,50	4,73	60,75	4,39	60,25	4,71
12	77,50	1,52	69,25	1,95	77,50	1,52
13	71,00	3,70	56,25	3,67	71,00	3,66
14	59,50	3,54	58,00	3,23	59,75	3,53
15	54,00	3,06	62,50	2,83	54,00	3,07
16	45,00	2,70	48,75	2,74	45,00	2,68
17	56,75	3,27	57,75	2,89	56,75	3,27
18	74,00	2,48	63,50	3,01	74,25	2,45
19	48,00	4,85	39,75	6,11	48,00	4,86
20	86,25	4,82	94,50	4,57	85,00	4,90
21	88,25	3,37	87,50	3,28	88,00	3,36
22	86,50	3,77	92,25	3,43	85,75	3,84
23	71,25	4,63	85,50	3,12	71,00	4,65
24	88,25	2,83	94,00	2,42	88,25	2,82
25	79,75	5,02	93,00	3,28	79,25	5,08
26	87,75	3,87	89,25	3,78	87,25	3,96
27	97,25	3,06	99,00	2,07	97,25	3,09
28	88,75	4,30	92,25	4,33	88,25	4,36
29	93,25	2,72	94,00	2,62	93,25	2,69
30	91,00	3,04	91,75	3,08	91,25	3,03
31	84,50	6,07	88,00	5,61	84,50	6,06
32	86,50	5,20	83,25	6,23	86,25	5,20
Média	80,61	3,22	80,27	3,16	80,52	3,22

De acordo com a Tabela VI, o melhor valor de acurácia médio para a *superclasse 0* foi de 96,83%, enquanto o menor desvio de classe foi de 1,16, ambos utilizando a função de distância *L1*. Para a *superclasse 1*, a maior acurácia média obtida foi 62,36%, por meio da distância *KL*. A diferença de 34,47% em relação a acurácia obtida na *superclasse 0* justifica-se pelo fato da *superclasse 1* possuir duas classes de fronteira

(classes 8/9 e 15/16). A acurácia média de 82,00% com a função *BC* foi o melhor valor para a *superclasse 2*.

TABELA VI
RESULTADOS OBTIDOS - HISTOGRAMAS DE TEXTURA (POR SUPERCLASSE)

Superclasse	Distância L1		Distância BC		Distância KL	
	Acurácia	Desvio	Acurácia	Desvio	Acurácia	Desvio
0	96,83	1,16	92,78	1,69	96,81	1,17
1	62,25	4,25	59,96	3,78	62,36	4,22
2	79,59	3,88	82,00	3,68	79,37	3,90
Média	79,56	3,10	78,25	3,05	79,51	3,10

Conforme mostrado nas Fig.s 7 e 8, os histogramas de textura gerados pela aplicação do método *LBP* são muito semelhantes entre as classes, mesmo para as mais distintas. Deste modo, torna-se mais difícil identificar a classe real da imagem por meio da distância entre os histogramas. Consequentemente, a acurácia do método proposto convergiu para melhores resultados quando aplicada aos histogramas de cor.

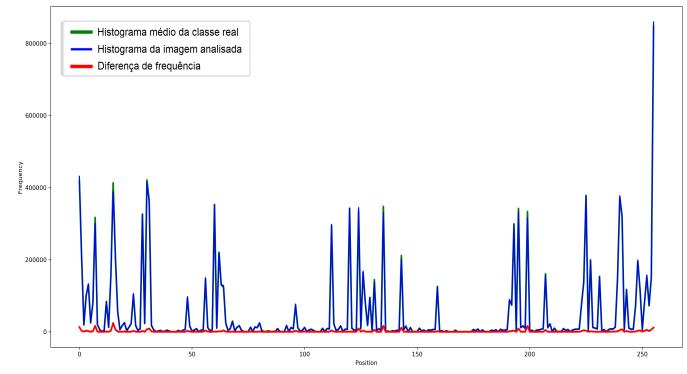


Fig. 7. Histograma de textura - classe estimada corretamente.

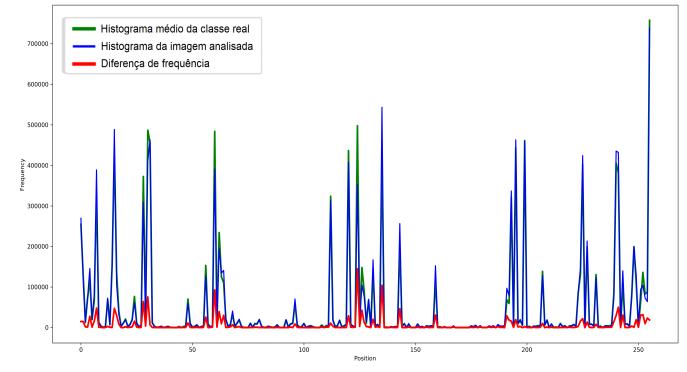


Fig. 8. Histograma de textura - classe estimada incorretamente.

Portanto, comparando os elementos de cor e textura, é possível notar que os resultados obtidos pelos histogramas de cor obtiveram a maior média de acurácia e os menores valores de desvio entre as classes. Para os elementos de textura, os resultados da *superclasse 1* foram relativamente afetados pelo fato de haver duas classes de fronteira (9 e 15), uma vez que os histogramas médios das classes 9 e 15 são bastante semelhantes aos histogramas das classes 8 (*superclasse 0*) e 16 (*superclasse 2*), respectivamente. Em relação às funções de

distância, pode-se notar um impacto importante nos resultados, uma vez que os melhores valores de acurácia foram obtidos por funções diferentes, de acordo com a superclasse.

V. CONCLUSÃO

Foi proposto no seguinte trabalho uma metodologia, baseada em técnicas de processamento de imagens e análise de características, para classificação e estimativa da quantidade de grãos de milho ardidos em uma amostra. O enfoque da pesquisa foi em grãos ardidos de milho, porém o estudo pode ser estendido a outros contextos de análise morfológica e detecção de diferentes tipos de uniformidades e descaracterização de grãos dentro desta cultura.

Por meio dos resultados obtidos por meio da análise supervisionada, foi possível demonstrar a viabilidade do método proposto, principalmente quando aplicado aos histogramas de cores das imagens.

Além disso, foi possível criar uma nova técnica para reduzir a subjetividade do método tradicional, aumentando a governança e a conformidade do processo atual de classificação dos grãos ardidos.

REFERÊNCIAS

- [1] CONAB - Companhia Nacional Abastecimento, “Acompanhamento da safra brasileira de grãos, safra 2020/21,” vol. 8, no. 7, 2021.
- [2] SENAR – Serviço Nacional de Aprendizagem Rural, “Grãos: Classificação de soja e milho,” no. 178, 2017.
- [3] A. Z. Zaccaron, C. P. Woloshuk, and B. H. Bluhm, “Comparative genomics of maize ear rot pathogens reveals expansion of carbohydrate-active enzymes and secondary metabolism backbone genes in *stenocarpella maydis*,” *Fungal Biology*, vol. 121, no. 11, pp. 966–983, 2017. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1878614617301095>
- [4] M. A. G. Pimentel, “Qualidade e classificação de grãos de milho colhidos e armazenados nas safras 2014/2015, 2015/2016 e 2016/2017,” 2020.
- [5] O. Resende, R. Quirino, E. Rosa, T. Souza, and C. Queiroz, “Caladores e homogeneizadores utilizados na amostragem de grãos em unidades armazenadoras,” *Agrarian*, vol. 13, pp. 593–601, 11 2020.
- [6] J. H. N. de Aquino, *Extração de características de imagens para classificação da qualidade de couro caprino usando padrão binário local*. Dissertação (Mestrado em Ciência da Computação)-Universidade Federal do Ceará, 2017.
- [7] M. Alsmadi, “Content-based image retrieval using color, shape and texture descriptors and features,” *Arabian Journal for Science and Engineering*, vol. 45, 02 2020.
- [8] S. Guo, T. Zhang, Y. Song, and F. Qian, “Color feature-based object tracking through particle swarm optimization with improved inertia weight,” *Sensors*, vol. 18, p. 1292, 04 2018.
- [9] A. Bhunia, A. Bhattacharyya, P. Banerjee, P. Roy, and S. Murala, “A novel feature descriptor for image retrieval by combining modified color histogram and diagonally symmetric co-occurrence texture pattern,” *Pattern Analysis and Applications*, vol. 23, 05 2020.
- [10] P. H. Gonçalves Dias Diniz, “Chemometrics-assisted color histogram-based analytical systems,” *Journal of Chemometrics*, 04 2020.
- [11] J.-x. Zhou, X.-d. Liu, T.-w. Xu, J.-h. Gan, and W.-q. Liu, “A new fusion approach for content based image retrieval with color histogram and local directional pattern,” *International Journal of Machine Learning and Cybernetics*, vol. 9, 04 2018.
- [12] R. C. Gonzalez and R. E. Woods, *Processamento de Imagens Digitais*. Editora Person Education do Brasil, 2009.
- [13] P. Liu, G. Jing, K. Chamnongthai, and H. Prasetyo, “Fusion of color histogram and lbp-based features for texture image retrieval and classification,” *Information Sciences*, vol. 390, 01 2017.
- [14] A. Humeau-Heurtier, “Texture feature extraction methods: A survey,” *IEEE Access*, vol. 7, pp. 8975–9000, 2019.
- [15] S. Ranganathan, K. Nakai, and C. Schönbach, *Encyclopedia of Bioinformatics and Computational Biology: ABC of Bioinformatics*, 01 2019.
- [16] E. Santucci, “Quantum minimum distance classifier,” *Entropy*, vol. 19, p. 659, 12 2017.
- [17] R. Abbaspour, M. Shaeri, and A. Chehreghan, “A method for similarity measurement in spatial trajectories,” *Spatial Information Research*, vol. 25, 05 2017.
- [18] P. Whigham, B. de Graaf, R. Srivastava, and P. Glue, “The importance of managing co-variate and distance biases in point-pattern clustering. geocomputation 2019,” Sep 2019.
- [19] E. Rodrigues, “Combining minkowski and chebyshev: New distance proposal and survey of distance metrics using k-nearest neighbours classifier,” *Pattern Recognition Letters*, vol. 110, pp. 66–71, 2018.
- [20] T. Strauss and M. von Maltitz, “Generalising ward’s method for use with manhattan distances,” *PLOS ONE*, vol. 12, p. e0168288, 01 2017.
- [21] Rizal, Fadlysyah, M. Muhamathir, and A. Akfal, “Detection system tajwid al quran on image using bray curtis distance,” vol. 2, 08 2015.
- [22] F. C. A. Flores, A. M. Polidório, and R. d. A. Lotufo, “The weighted gradient: a color image gradient applied to morphological segmentation,” *Journal of the Brazilian Computer Society*, vol. 11, pp. 53 – 63, 04 2006.
- [23] H. Chen, B. Jiang, and N. Lu, “An improved incipient fault detection method based on kullback-leibler divergence,” *ISA Transactions*, vol. 79, pp. 127–136, 2018.
- [24] F. Harrou, Y. Sun, and M. Madakyaru, “Kullback-leibler distance-based enhanced detection of incipient anomalies,” *Journal of Loss Prevention in the Process Industries*, vol. 44, pp. 73–87, 11 2016.



Gustavo Viais de Brito Silva Graduado em Engenharia de Computação pela Universidade Tecnológica Federal do Paraná (2016) e Mestrando em Ciências da Computação pela Universidade Estadual de Maringá (ingressante em 2019). Possui experiência profissional em desenvolvimento de sistemas e ciência de dados aplicada ao agronegócio.



Franklin César Flores received his Bachelor in Computer Science from the State University of Maringá, Brazil, in 1998. He received his MSc degree from University of São Paulo, Brazil, in 2000, and his PhD degree from State University of Campinas, Brazil, in 2009. Post-doctoral position at University of Bath, UK, in 2014. He is currently an adjunct professor in the Department of Informatics at the State University of Maringá, Brazil. His interests include Digital Image Processing, Mathematical Morphology and Pattern Recognition.